

Scouting Vetorial VNL 2025

Motor de similaridade de jogadores
com o banco vetorial Qdrant

Participantes

Gustavo Nogueira
Isabella Comelli
Lucas Ladeira

Orientação

Prof^a. Dr^a.
Jeaneth Machicao



Problema de negócio

O Desafio do Scouting

Comissões técnicas e olheiros precisam encontrar jogadores com perfil de jogo parecido a um atleta de referência, sugerindo substitutos ideais por critérios de posição, idade e estatísticas.

Base de Dados

Dataset Kaggle VNL 2025 Mens, contendo as estatísticas individuais reais de 339 atletas da Volleyball Nations League de 2025.

Diretriz de Arquitetura: Query-First Design

O banco de dados é escolhido e estruturado com base nos padrões de acesso necessários, e não o contrário.



Por que o Qdrant? (Banco Vetorial)

A SOLUÇÃO ESCOLHIDA: Busca por Similaridade

Especializado em buscas por similaridade entre vetores e com suporte a filtro de payload, tornando as consultas incomparavelmente mais eficientes do que em bancos tradicionais.

Cada jogador vira um vetor (perfil estatístico); nome, seleção, posição, idade, altura e estatísticas do jogo ficam armazenados no payload de metadados.



NÃO É CADASTRO TRANSACIONAL: Descarta MongoDB / DynamoDB

A aplicação exige busca vetorial por proximidade e similaridade de perfil, e não operações tradicionais de leitura/escrita de documentos ou tabelas.

NÃO É SÉRIE TEMPORAL: Descarta Cassandra

Não há necessidade de ingestão massiva e contínua de dados em tempo real ou gravação de séries temporais de alta frequência.

NÃO É RELACIONAMENTO EM REDE: Descarta Neo4j

Embora existam conexões de equipe, o foco absoluto é a similaridade multidimensional dos atributos físicos e estatísticos do jogador, não caminhos de rede complexos.

Requisitos Funcionais

A jornada de scouting traduzida em 7 necessidades de negócio:

RF01 · SIMILARIDADE VETORIAL

Encontrar jogadores semelhantes

"Quem joga como o Darlan?"

RF02 · BUSCA HÍBRIDA

Substitutos por posição e idade

"Quem o substitui, mesma posição e mais jovem?"

RF03 · FILTRO DE METADADOS

Consultar jogadores por seleção

"Quem está no elenco do Brasil?"

RF04 · SIMILARIDADE VETORIAL

Buscar a partir de um perfil ideal

"Quero um oposito com este perfil de ataque"

RF05 · FILTRO DE METADADOS

Filtrar por características físicas

"Opostos $\geq 2,00m$, brasileiros, até 25 anos"

RF06 · ESCRITA (UPSERT)

Atualizar estatísticas dos atletas

"Chegaram os números da nova rodada"

RF07 · LOOKUP DIRETO

Recuperar jogador por ID

"Abrir a ficha completa do atleta"

DIRETRIZ DE PROJETO

"Query-First Design: O banco de dados é estruturado com base nos padrões de acesso necessários."

Application Workflow: Padrões de acesso (Q1-Q7)

SIMILARIDADE PURA (VETORIAL)

Q1: Similares a um jogador - Busca puramente vetorial por proximidade de perfil

Q4: Perfil ideal sintético - Geração de perfil alvo e busca vetorial pura

HÍBRIDO (VETOR + FILTRO)

Q2: Substituto - Busca por similaridade com filtro de posição e limite de idade

FILTROS DE METADADOS & LOOKUP (PAYLOAD/ID)


Q3: Elenco de uma seleção - Filtro pelo payload de metadados da seleção

Q5: Jogadores observados - Filtro múltiplo (altura / nacionalidade / idade)

Q7: Perfil completo por ID - Lookup direto pelo identificador do atleta

ESCRITA (UPSERT)

Q6: Atualizar estatísticas - Operação de escrita/upsert para atualização de dados



Por que distância de Cosseno?

Queremos "**quem joga parecido**". Isto é, o mesmo *padrão* entre os fundamentos, não o mesmo *volume absoluto* de números.

COSSENO: POR QUE É A MÉTRICA IDEAL?

Mede Direção, não Tamanho

Dois opostos com o mesmo estilo ficam próximos mesmo que um seja titular e outro reserva. O que importa é a proporção entre os fundamentos.

Padrão como Identidade

A posição em quadra é definida por um padrão, não por magnitude. Ponteiros atacam, líberos defendem, levantadores levantam. O cosseno captura com precisão essa parte tática.

OUTRAS MÉTRICAS: POR QUE EVITAR?

Por que não Euclidiana?

Ela penaliza a diferença de volume. Jogadores com o mesmo perfil técnico, mas tempos de quadra distintos, pareceriam "distantes". Confunde "jogar diferente" com "jogar mais".

Por que não Dot Product?

Favorece vetores de alta magnitude. Como consequência, as estrelas dominariam os resultados

Vetor de 10 dimensões

Regra uniforme por fundamento do vôlei; distância por cosseno

VOLUME (peso 1.0)

Ataque, bloqueio, saque, backcourt (defesa+recepção) e levantamento.

Medem quanto o jogador atua e definem a sua função ou posição primária em quadra.

EFICIÊNCIA (peso 0.4)

Taxa de execução = sucesso / (sucesso + erro) de cada fundamento técnico analisado.

Ajusta o indicador final pela qualidade técnica real sem sequestrar a definição da função.

Métrica e Normalização

Cada feature é normalizada com min-max $[0,1]$ antes da aplicação do peso correspondente. A distância por cosseno foca em comparar o formato do perfil técnico do atleta, desconsiderando a magnitude absoluta do volume de jogo.

Coleção e Payload

COLEÇÃO

jogadores_vnl_2025

Busca de similaridade baseada em distância por cosseno.

PAYLOAD (METADADOS)

Dados demográficos, táticos e estatísticos armazenados fora do vetor de busca para visualização direta:

- **player_name**, **team**, **nationality**, **position**, **age**, **height_cm**
- **stats_raw**, **efficiency** (kill%, ace%, block%, reception%, setting%)

ÍNDICES E FILTRO

Filtros rápidos por: position, team, nationality, age, height_cm.


Jogadores com menos de 10 ações são descartados.

Resultado: 310 pontos.


payload_jogador.json

```
// Payload JSON de um jogador
{
  "player_name": "Darlan",
  "team": "BRA",
  "nationality": "BRA",
  "position": "OPPOSITE SPIKER",
  "age": 23,
  "height_cm": 192,
  "stats_raw": {
    "attacks_per_match": 8.13,
    "kills": 122,
    "attacking_attempts": 58,
    "blocks_per_match": 0.33,
    "serves_per_match": 1.0,
    "aces": 15,
    "digs_per_match": 1.27,
    "receives_per_match": 0.0,
    "sets_per_match": 0.0
  },
  "efficiency": {
    "kill_pct": 55.7,
    "ace_pct": 14.6,
    "block_pct": 13.9,
    "reception_pct": 0.0,
    "setting_pct": 100.0
  }
}
```

Coleção: Projeção 2D



- Líbero
- Central
- Oposto
- Ponta
- Levantador



PoC: Resultados das Consultas

Q1: Similares a Darlan (oposto BRA)

5 opositos - Romano, Gomez, Rychlicki, Jiang, Garcia; score ≥ 0.97 .

Q2: Substitutos (idade até 27)

5 opositos - Gomez, Garcia, Ketrzynski, Antov, Miyaura; score ≥ 0.96 .

Q5: Altura ≥ 200 , BRA, idade até 25

Adriano, Arthur, L. Bergmann, Thiery.



Análise de Clusters

O vetor captura a função

Clusters por posição (líbero, levantador e central) mostram-se **bem separados**.

Ponteiro e oposto se sobrepõem, o que é **esperado** pela semelhança de suas funções táticas na quadra.

Desafios e lições

▣ Separação de Posições

Desafio: A eficiência de recepção aproximava, por exemplo, o líbero do ponteiro nos dados.

Solução: **Resolvido diminuindo peso das features de eff%.**

▣ Cálculo de Eficiência

Desafio: Colunas 'Attempts' contavam só bolas em jogo, distorcendo métricas (kill% passava de 100%).

Solução: **Total definido como sucesso + erro + em jogo.**

▼ Corte de Volume Mínimo

Filtro de Ruído: Atletas com pouca participação poluem as métricas de similaridade.

Critério: **Descarte de jogadores com menos de 10 ações para manter a relevância da base.**

Conclusão

Query-First Design

Levou naturalmente à adoção de um **banco vetorial**, priorizando a similaridade de perfis e os padrões de acesso mais frequentes.

Qdrant & PoC Real

Entrega eficiente de consultas **Q1-Q7** com vetor de 10 dimensões e payload filtrável.
PoC com 310 atletas reais.

Validação Visual

A análise gráfica e a projeção espacial confirmam que o vetor captura com precisão a **função tática e a posição** dos atletas em quadra.

Próximos Passos

Criação de dashboards interativos no **Power BI** e desenvolvimento de uma **REST API**.
Expansão para a Superliga e torneios internacionais.