

Grupo E - eEDB-016/2026-2 - Repositório de Dados e NoSQL

Gustavo Nogueira

Isabella Comelli

Lucas Ladeira

Domínio e aplicação

A aplicação fictícia é um motor de scouting estatístico para a Volleyball Nations League, usado por comissões técnicas e olheiros para encontrar jogadores com perfil de jogo parecido a um atleta de referência, ou sugerir substitutos dentro de critérios específicos. A base do Kaggle (VNL 2025 Men's) fornece o conteúdo factual: jogadores, seleções, posições e estatísticas individuais de ataque, bloqueio, saque e recepção.

Tecnologia e Justificativa: Qdrant

O padrão de acesso predominante aqui não é cadastro transacional (descarta MongoDB ou DynamoDB), não é ingestão massiva de séries temporais (descarta Cassandra), e não é navegação entre relacionamentos de rede (descarta Neo4J). A necessidade central é responder à pergunta "quem joga de forma parecida com este atleta", o que é, por definição, um problema de similaridade em espaço vetorial. Cada jogador é representado por um vetor numérico construído a partir de suas métricas normalizadas de desempenho, e os dados de negócio (nome, seleção, posição, idade, altura) ficam no payload de metadados, exatamente como pede a matriz de decisão do enunciado.

Etapa 1, Requisitos Funcionais (Q1 a Q7)

- RF01: Encontrar jogadores estatisticamente semelhantes.
- RF02: Encontrar substitutos respeitando posição e idade.
- RF03: Consultar jogadores por seleção.
- RF04: Buscar jogadores a partir de um perfil estatístico ideal.
- RF05: Filtrar jogadores por características físicas.
- RF06: Atualizar estatísticas dos atletas.
- RF07: Recuperar um jogador pelo identificador.

Etapa 1, padrões de acesso (Q1 a Q7)

As consultas previstas para o sistema são apresentadas a seguir e representam os principais padrões de acesso que deverão ser suportados pela aplicação.

1. Q1, busca vetorial pura: dado um jogador de referência, retornar os N jogadores com perfil estatístico mais próximo, ordenados por similaridade de cosseno (sem nenhum filtro de payload).
2. Q2, busca vetorial combinada com filtro de payload: dado um jogador de referência, encontrar um substituto estatístico restringindo o resultado por posição igual e por faixa de idade, e opcionalmente excluindo jogadores da mesma seleção.
3. Q3, filtro puro de payload: listar todos os jogadores de uma seleção específica, ordenados por posição ou por nome, sem nenhum componente de similaridade vetorial.
4. Q4, busca vetorial pura com vetor sintético: o usuário define manualmente os valores desejados de eficiência de ataque, bloqueio e saque (sem partir de um jogador existente), o sistema monta um vetor de consulta a partir desses valores e retorna os jogadores reais mais próximos desse perfil ideal.
5. Q5, filtro puro de payload com múltiplas condições: montar uma lista de observação filtrando por faixa de altura, nacionalidade e idade, ordenada por altura ou por idade, sem componente vetorial.
6. Q6, atualização (upsert): inserir ou recalculando o vetor e o payload de um jogador depois que novas estatísticas de uma rodada ou temporada ficam disponíveis.
7. Q7, busca direta por identificador: recuperar o payload completo de um jogador específico a partir do seu id, usado para abrir a tela de perfil a partir de qualquer resultado anterior de busca.

A base de dados utilizada é o dataset VNL 2025 Mens, disponibilizado publicamente na plataforma Kaggle pelo usuário [owenhoag07](#). O dataset agrega estatísticas individuais dos jogadores que participaram da edição masculina de 2025 da Volleyball Nations League, organizada pela FIVB. Os registros incluem informações cadastrais de cada atleta, como nome, seleção, posição, nacionalidade, idade e altura, além de métricas de desempenho coletadas ao longo da competição, entre elas eficiência de ataque, pontos de bloqueio por set, aces por set, erros de saque por set e eficiência de recepção.

Para fins da prova de conceito, os atributos do dataset foram divididos em dois grupos conforme a função que exercem na coleção do Qdrant. O primeiro grupo alimenta o vetor de embedding: as métricas de desempenho são normalizadas (escala min-max calculada sobre o conjunto completo de jogadores) e concatenadas em um vetor de dimensão fixa, que representa o perfil estatístico de jogo de cada atleta no espaço vetorial. O segundo grupo compõe o payload de metadados armazenado junto ao ponto: nome, seleção, posição, nacionalidade, idade e altura em centímetros, que permitem aplicar filtros diretos nas consultas Q2, Q3 e Q5 sem recorrer ao componente vetorial.


Os pontos populados na coleção são fictícios, mas construídos de forma consistente com os valores e distribuições observados no dataset original, atendendo ao requisito de dados simulados com coerência de domínio estabelecido na etapa 3 do enunciado.

Etapa 2, modelagem lógica e física

Coleção: jogadores_vnl_2025.

- Métrica de distância: cosseno, porque o objetivo é comparar o formato do perfil estatístico de cada jogador (estilo de jogo), não a magnitude absoluta dos números.
- Dimensão do vetor: composta pelas métricas normalizadas (min max ou z score, calculadas sobre todos os jogadores da base) de eficiência de ataque, pontos de bloqueio por set, aces por set, erros de saque por set, eficiência de recepção, taxa de excelência de levantamento (quando aplicável à posição), entre outras métricas relevantes disponíveis no dataset.
- Id do ponto: identificador determinístico do jogador (por exemplo, nome normalizado mais temporada), usado diretamente em Q6 e Q7.

Payload de metadados (esquema JSON), com índices de payload criados para os campos usados como filtro em Q2, Q3 e Q5 (posicao, selecao, nacionalidade, idade, altura_cm):



The screenshot shows a Qdrant interface with a dark theme. At the top, it says "Point 58". Below that, there's a "Payload" label with a copy icon and an edit icon. The main content is a JSON object representing a player's data. The JSON is as follows:

```
{
  "player_name": "Darlan",
  "team": "BRA",
  "nationality": "BRA",
  "position": "OPPOSITE SPIKER",
  "age": 23,
  "height_cm": 192,
  "stats_raw": {
    "attacks_per_match": 8.13,
    "kills": 122,
    "attacking_attempts": 58,
    "blocks_per_match": 0.33,
    "serves_per_match": 1,
    "aces": 15,
    "digs_per_match": 1.27,
    "receives_per_match": 0,
    "sets_per_match": 0
  },
  "efficiency": {
    "kill_pct": 55.7,
    "ace_pct": 14.6,
    "block_pct": 13.9,
    "reception_pct": 0,
    "setting_pct": 100
  }
}
```

Figura 1. Payload de um jogador no Qdrant.

Descrição dos campos do payload (metadados)

Informações Gerais

Campo	Descrição
player_name	Nome do jogador.
team	Sigla ou nome da equipe do jogador.
nationality	Nacionalidade do jogador.
position	Posição em que o jogador atua.
age	Idade do jogador em anos.
height_cm	Altura do jogador, em centímetros.

Estatísticas Brutas (stats_raw)

Campo	Descrição
attacks_per_match	Média de ataques realizados por partida.
kills	Total de ataques que resultaram em ponto.

attacking_attempts	Total de tentativas de ataque.
blocks_per_match	Média de bloqueios realizados por partida.
serves_per_match	Média de saques realizados por partida.
aces	Total de aces (saques que resultaram diretamente em ponto).
digs_per_match	Média de defesas realizadas por partida.
receives_per_match	Média de recepções realizadas por partida.
sets_per_match	Média de levantamentos (sets) realizados por partida.

Indicadores de Eficiência (efficiency)

Campo	Descrição
kill_pct	Percentual de eficiência nos ataques, calculado como o número de ataques que resultaram em ponto dividido pelo total de tentativas de ataque.
ace_pct	Percentual de eficiência nos saques, calculado como o número de aces dividido pelo total de saques executados.
block_pct	Percentual de eficiência nos bloqueios, calculado como o número de bloqueios convertidos em ponto dividido pelo total de tentativas de bloqueio.

reception_pct Percentual de eficiência nas recepções, calculado como o número de recepções bem-sucedidas dividido pelo total de tentativas de recepção.

setting_pct Percentual de eficiência nos levantamentos, calculado como o número de levantamentos bem-sucedidos dividido pelo total de tentativas de levantamento.

Diagrama:




Figura 2. Application Workflow Diagram do motor de scouting VNL. Caixas em verde indicam acesso sem componente vetorial (filtro de payload ou busca direta por id). Caixas em coral indicam busca vetorial pura. Caixas em rosa indicam busca vetorial combinada com filtro de payload.

Evidências de Execução do Qdrant:




Figura 3. Interface do Qdrant apresentando o primeiro payload da coleção.



Figura 4. Grafo que apresenta a ligação do primeiro ponto até o ponto 58, pertencente ao brasileiro Darlan.